

Avaliação de Técnicas de Calibração para um Software de Eye Tracking

Isadora Coelho Faggiani, Leonardo Ribeiro Silva, Rita Elizabeth Santos de Almeida,
Marcelo Vinícius Cysneiros Aragão & Juliano Augusto Nascimento Leite

Abstract— This article explores the critical aspect of Eye Tracking software calibration for accurate focal point detection and discusses techniques to enhance the process. A literature review was conducted initially to understand challenges and outlier removal methods. The article presents methods, including K-means for calibration and IQR, ECOD, or LOF for outlier removal. Qualitative and quantitative studies assessed these techniques, gathering participants' opinions and using metrics like Silhouette Score and Calinski-Harabasz. The article provides insights into improving data treatment for the Eye Tracking software calibration challenge.

Index Terms— Eye Tracking, Calibration, Clustering, Outlier Removal

Resumo— Este artigo aborda a calibração do software *Eye Tracking*, crucial para a precisão na detecção do ponto focal do usuário, e explora técnicas para aprimorar esse procedimento. Inicialmente, uma revisão bibliográfica foi realizada para abordar desafios no rastreamento ocular e técnicas de remoção de outliers. O trabalho discute métodos de melhoria da calibração, incluindo o uso do algoritmo K-means e a remoção de outliers por meio do IQR, ECOD ou LOF. Estudos qualitativos e quantitativos foram conduzidos para avaliar essas técnicas, coletando opiniões dos participantes e utilizando métricas como Silhouette Score e Calinski-Harabasz. O artigo proporciona uma visão ampla sobre o tratamento de dados e a abordagem de técnicas relacionadas ao desafio da calibração no software *Eye Tracking*.

Palavras Chave— Rastreamento Ocular, Calibração, Agrupamento, Remoção de Outliers

I. INTRODUÇÃO

Sabe-se que o mundo é repleto de informações visuais e, a maneira como nossos olhos se movem e processam essas informações, desempenha um papel fundamental na compreensão do ambiente que nos cerca. Tecnologias são criadas para acompanhar este progresso, como a de rastreamento ocular (do inglês, *Eye Tracking*), que é um dispositivo ou sistema de software capaz de promover o rastreamento e a gravação do comportamento ocular de um indivíduo em um determinado ambiente, identificando para onde ele dirige o seu olhar e registrando informações como a duração de tempo da atividade visual, a dilatação da pupila e a trajetória da movimentação do olhar [1].

Em geral, a movimentação ocular pode ser resumida na combinação de quatro movimentos básicos: sacadas, fixações, perseguições suaves e nistagmo. Duchowski [2] define cada técnica de visualização como:

Trabalho de Conclusão de Curso apresentado ao Instituto Nacional de Telecomunicações, como parte dos requisitos para a obtenção do Grau de Bacharel em Engenharia Biomédica. Orientador: Prof. Me. Marcelo Vinícius Cysneiros Aragão. Trabalho aprovado em DD/MM/AAAA.

- Sacadas: são movimentos voluntários e reflexivos, considerados desejos voluntários de mudar o foco da atenção;
- Fixações: as fixações são caracterizadas pelos movimentos oculares em miniatura, como tremor, deriva e microsacadas. São ditas como comportamentos nos quais sozinhos permanecem estacionários em algum aspecto do ambiente;
- Perseguições suaves: dependem da amplitude do movimento do alvo e podem ocorrer em qualquer meridiano. São dados como movimentos lentos e contínuos;
- Nistagmo: é a combinação de diversos movimentos pequenos. É um mecanismo acoplado dos olhos, com a função de estabilizar os olhos e garantir uma visão nítida.

O *Eye Tracking* revolucionou inúmeras áreas da ciência, tecnologia e *design*, fornecendo uma visão sem precedentes do comportamento humano e da interação com o mundo visual. Essa tecnologia, que permite rastrear os movimentos oculares precisamente e não intrusiva, desempenha um papel crítico na compreensão das preferências, interesses e tomadas de decisões dos indivíduos. É importante observar que o *Eye Tracking* cumpre um importante papel como método de pesquisa, uma vez que fornece diversas métricas para análises e interpretações, mas deve ser acompanhado por uma teoria que explique os fenômenos observados durante as visualizações [3].

No entanto, o desenvolvimento de sistemas de rastreamento ocular, embora promissor, também traz desafios significativos. Dentre todos os obstáculos, a calibração emerge como uma das etapas mais cruciais e desafiadoras.

A calibração é o processo pelo qual o sistema de rastreamento ocular encontra uma função de mapeamento que mapeia as coordenadas relatadas pelo rastreador ocular para as coordenadas de um ponto de olhar no ambiente visual [4]. Desse modo, a qualidade dos dados refere-se à confiabilidade, validade e disponibilidade dos dados de rastreamento ocular, podendo ser expresso com as medidas de precisão, exatidão e perda de dados. Isso implica a necessidade de estabelecer uma correspondência precisa entre a direção do olhar do usuário e os pontos de referência na tela ou no ambiente. Em outras palavras, a calibração é a chave para garantir que o rastreamento ocular funcione com a maior precisão possível, capturando com exatidão os movimentos oculares do usuário [5].

Desse modo, o *Eye Tracking* concentra na parte da calibração um dos principais desafios no desenvolvimento de sistemas de rastreamento ocular. A precisão da calibração é essencial para garantir que os dados coletados sejam confiáveis, permitindo que os pesquisadores, *designers* e profissionais de diversas áreas tomem decisões informadas e baseadas em evidências.

Técnicas e tecnologias inovadoras são desenvolvidas e incorporadas no *software* para enfrentar o desafio da calibração e aprimorar, ainda mais, este campo. Assim, é evidente como a calibração é uma parte mais crítica e intrigante no aperfeiçoamento desta tecnologia, prometendo *insights* cada vez mais profundos sobre a relação entre o olhar humano e o mundo visual que nos rodeia.

Objetiva-se analisar diferentes técnicas de calibração para um *Software de Eye Tracking*. A fim de encontrar resultados precisos, serão abordadas diferentes métodos para remoção de *outliers* e métricas de avaliação qualitativas e quantitativas do conjunto de dados referente ao rastreamento ocular.

II. REVISÃO DA TEORIA

A. Eye Tracking

É uma técnica utilizada para registrar o movimento dos olhos e a direção do olhar ao longo do tempo. Em 1823, Charles Bell estabeleceu uma conexão fisiológica entre os olhos e o sistema nervoso, abrindo caminho para a investigação dos processos mentais. Antes com um alto custo e trabalhoso, após anos de pesquisas e avanços tecnológicos, o *Eye Tracking* se tornou mais acessível. Atualmente é aplicado em diversas áreas como psicologia, medicina, neurociência, *marketing* e outras [6].

Há diversos métodos de rastreamento ocular, incluindo abordagens baseadas em forma, características e aparência, que procuram identificar tanto movimentos rápidos dos olhos quanto períodos de fixação. Além disso, o *Eye Tracking* é aplicado em quatro técnicas principais, sendo elas:

- Bobina de busca escleral: utiliza uma lente de contato com espelhos acoplados a uma bobina de fio que se move em um campo magnético, possibilitando a detecção precisa do movimento ocular;
- Oculografia por infravermelho (IOG): mede a luz infravermelha refletida da esclera para determinar a posição do olhar, sendo menos invasiva do que a técnica da bobina;
- Eletrooculografia (EOG): utiliza sensores para medir o campo elétrico gerado pelos movimentos oculares;
- Oculografia por vídeo (VOG): registra os movimentos dos olhos por meio de uma câmera, sendo uma técnica não invasiva amplamente utilizada.

Cada técnica possui vantagens e limitações, tornando-as adequadas para diferentes aplicações e cenários [7].

B. Remoção de Outliers

No contexto da análise de dados, um ponto muito importante e fundamental para a fomentação da pesquisa é garantir a qualidade dos dados. Desse modo, a busca pela compreensão de um conjunto de informações muitas vezes é desafiada por valores atípicos que parecem escapar das tendências e padrões identificados. Esses valores indesejáveis podem ser chamados de “*outliers*” e podem ser definidos como dados que se diferenciam drasticamente de todos os outros. Em outras palavras, um *outlier* é um valor que foge da normalidade e que pode causar anomalias nos resultados obtidos por meio de algoritmos e sistemas de análise [8].

A presença de valores discrepantes é uma ocorrência frequente em várias disciplinas e demanda atenção especial durante a análise, uma vez que pode influenciar as conclusões e comprometer a qualidade das inferências estatísticas. Além disso, esses pontos discrepantes podem servir para identificar sutilezas antes ocultas nos dados, proporcionando percepções valiosas sobre os processos e os sistemas que o geraram. Assim, é extremamente importante verificar se os pontos atípicos aconteceram devido à variabilidade nos dados ou devido a um erro experimental/erro humano.

No entanto, mesmo sendo um empecilho geralmente, alguns *outliers* são benéficos e extremamente importantes para indicarem que os dados são altamente diferentes de outros. Nesse contexto, podem apontar uma anomalia, como fraude bancária ou uma doença rara, sendo considerados uma das maneiras mais simples de solucionar, ou inspecionar um caso específico [9].

Devido às situações que são necessárias que haja a retirada dos dados fora da normalidade, algumas técnicas foram criadas para serem incorporadas na análise de dados e assim fazer com que o estudo seja coerente. Desse modo, existem várias abordagens e ferramentas disponíveis para tratar *outliers* e a escolha da melhor estratégia depende do contexto específico do problema e da natureza dos dados.

b.1. IQR

O Intervalo Interquartil (IQR) é uma ferramenta estatística que analisa e identifica valores irregulares em conjuntos de dados. O IQR é empregado para avaliar a variabilidade ao dividir um conjunto de dados em quartis. Esses dividem um conjunto ordenado de dados em quatro partes iguais. Como visto na equação (1), seu cálculo é bastante simples:

$$IQR = Q3 - Q1 \quad (1)$$

Sendo:

- $Q1$ é o primeiro quartil (25° percentil);
- $Q3$ é o terceiro quartil (75° percentil).

Esse cálculo proporciona uma medida da dispersão dos dados que não é sensível a *outliers*, tornando-o robusto em comparação com outras estatísticas. A natureza do IQR o torna particularmente útil na detecção de valores extremos que poderiam distorcer análises estatísticas.

Primeiramente, calcula-se o IQR conforme a equação mencionada. Em seguida, multiplica-se o IQR por 1,5. Os limites superior (L_S) e inferior (L_I) são obtidos adicionando e subtraindo esse valor de $Q3$ e $Q1$, respectivamente. Assim, qualquer ponto de dados que esteja acima do limite superior (2), ou abaixo do limite inferior (3), é classificado como um valor atípico.

$$L_S = Q3 + 1,5 \times IQR \quad (2)$$

$$L_I = Q1 - 1,5 \times IQR \quad (3)$$

Sendo:

- L_S é o limite superior;
- L_I é o limite inferior;
- $Q1$ é o primeiro quartil (25° percentil);
- $Q3$ é o terceiro quartil (75° percentil);
- IQR é o intervalo interquartil.

A remoção de *outliers* com base no IQR proporciona uma abordagem equilibrada, eliminando valores discrepantes que podem distorcer análises estatísticas sem comprometer a integridade do conjunto de dados na totalidade. No entanto, é preciso ter cautela ao remover valores discrepantes, pois, em alguns casos, podem conter informações importantes ou representar situações relevantes para o fenômeno estudado[9].

b.2. ECOD

Empirical-Cumulative-distribution-based Outlier Detection (ECOD) é uma técnica sofisticada empregada para identificar e tratar dispersões em conjuntos de dados espaciais. Sua abordagem é fundamentada na ideia de que os *outliers* geralmente se apresentam como eventos raros localizados nas extremidades de uma distribuição. Para operar, o ECOD começa estimando a distribuição dos dados de entrada de forma não paramétrica. Isso é feito por meio do cálculo da distribuição empírica cumulativa por dimensão dos dados, ajudando a compreender melhor a estrutura dos dados e a identificar padrões incomuns.

Em seguida, com base nessas distribuições empíricas, o ECOD estima as probabilidades de ocorrência nas extremidades para cada ponto de dados. Por fim, o ECOD calcula uma pontuação atípica de cada ponto de dados agregando probabilidades de cauda estimadas entre dimensões [10]. Isso ajuda a destacar pontos de dados que se desviam significativamente do comportamento esperado, permitindo uma identificação mais precisa dos *outliers*.

Uma das principais vantagens do ECOD é sua capacidade de ser facilmente interpretado. Além disso, o fato de ser isento de parâmetros torna-o uma opção descomplicada, enquanto ainda mantém altos níveis de precisão, eficiência e escalabilidade, tornando-o uma escolha atraente para análise de dados.

b.3. LOF

O *Local Outlier Factor* (LOF) é uma técnica amplamente reconhecida e utilizada para identificar valores discrepantes em dados. É baseado na ideia de densidade local, onde a densidade em torno de uma amostra é comparada com a densidade ao redor de seus vizinhos. O fator de *outlier* local de uma amostra é calculado como a média das razões da densidade local da amostra e das densidades locais de seus vizinhos. Um valor de LOF significativamente maior do que um, indica um valor disperso.

O LOF pode ser aplicado em diferentes áreas, como detecção de fraude, monitoramento de redes e análise de dados ambientais. Sua capacidade de lidar com diferentes tipos de dados e de se adaptar a diferentes distribuições de dados o tornam uma ferramenta valiosa em múltiplos domínios do conhecimento [11].

Apesar de sua utilidade, o LOF tem limitações. A escolha dos parâmetros, como o número de vizinhos, pode afetar significativamente os resultados. Dessa forma, melhorias como a introdução de parâmetros adaptativos ou a combinação com outras técnicas de aprendizado de máquina para aumentar a precisão na detecção de *outliers* podem ser necessárias [12].

C. Clustering

Clustering é uma técnica amplamente empregada na análise e mineração de dados, visando agrupar objetos semelhantes em *clusters* ou grupos com base em características compartilhadas.

Além disso, nesta revisão teórica, discutiremos não apenas o algoritmo *K-means*, mas também duas métricas cruciais para avaliar a qualidade dos conjuntos produzidos: o índice Calinski-Harabasz e o *Silhouette Score*.

O algoritmo *K-means* é um dos métodos mais populares de *clustering* e se baseia na ideia de pontos centrais. Ele começa selecionando os pontos iniciais como centros e, em seguida, atribui cada ponto de dados ao grupo em que o centro está mais próximo. Em seguida, recalcula os centros como a média dos pontos atribuídos a cada *cluster* e repete esse processo até a convergência. O *K-means* é uma abordagem eficaz e de fácil implementação, mas sua eficácia pode ser prejudicada caso o algoritmo faça escolhas iniciais ruins para os centros.

Para avaliar a qualidade dos conjuntos de dados gerados pelo *K-means*, duas métricas amplamente utilizadas são o índice Calinski-Harabasz e o *Silhouette Score*.

O índice Calinski-Harabasz, também conhecido como critério de validação da variância, avalia a dispersão entre os agrupamentos e a dispersão dentro deles. Ele visa maximizar a relação entre essas duas dispersões, sugerindo uma separação eficaz entre os valores associados. Um valor mais alto no índice Calinski-Harabasz indica uma separação mais eficiente dos *clusters*.

O *Silhouette Score*, em contrapartida, avalia a coesão nos *clusters* e a separação entre eles. Ele fornece um valor entre -1 e 1, onde valores próximos de 1 indicam que os objetos estão bem separados entre os conjuntos, valores próximos de 0 indicam sobreposição entre os *clusters* e valores negativos indicam que os objetos foram atribuídos erroneamente aos conglomerados. Portanto, quanto maior o *Silhouette Score*, melhor a qualidade do agrupamento.

c.1. Algoritmo *K-means*

O algoritmo *K-means* padrão, originalmente proposto em 1957 por Stuart Lloyd, foi publicado somente nos laboratórios Bell, que historicamente foram centros de inovações cruciais no campo tecnológico, tais como a invenção dos transistores, a fibra óptica, satélites de comunicação e a linguagem de programação C. Posteriormente, em 1965, uma versão do mesmo método foi publicada por E. W. Forgy, conferindo a este algoritmo a designação de Lloyd-Forgy. Uma versão ainda mais aprimorada do algoritmo foi apresentada em 1979 por Hartigan e Wong, sendo desenvolvida em linguagem Fortran, demonstrando uma eficiência consideravelmente superior. [13, 14].

O algoritmo *K-means* é um método de aprendizado de máquina não supervisionado, o seja, não requer que as amostras sejam rotuladas. Esse algoritmo é empregado para agrupar dados com base em suas semelhanças[15]. A aplicação do *K-means* é amplamente difundida na mineração de dados, e seu principal objetivo é realizar a *clusterização*[16].

Para a utilização do algoritmo é imprescindível ser possível calcular a média entre os conjuntos de dados e a distância euclidiana entre esses pontos. Assim sendo, é comum que os dados de entrada sejam representados no formato de vetores numéricos[16].

A aplicação do *K-means* começa pela definição do número de grupos desejados, denominados *clusters*. Em seguida, um centroide é aleatoriamente atribuído a cada conjunto, e através

do cálculo da distância euclidiana, determina-se a qual desses conjuntos cada ponto de dado pertence. Depois que todos os pontos foram atribuídos aos seus respectivos grupos, é calculada a média dos pontos em cada conjunto individualmente. Os centroides são então repositionados de acordo com essas médias, e os pontos são novamente alocados com base no centroide mais próximo. Esse processo se repete até que os pontos estejam devidamente distribuídos nos *clusters* apropriados [17].

c.2. Silhouette Score (SS)

O *Silhouette Score* é uma métrica amplamente empregada na avaliação de algoritmos de *clustering*, desempenhando um papel fundamental na validação dos resultados obtidos durante o processo de agrupamento de dados, comumente empregado em estudos acadêmicos e projetos de análise de dados [18].

A análise busca por meio de uma faixa de valores, -1 e $+1$, quantificar o quanto bem agrupado estão os dados, de modo que -1 indique que os pontos foram agrupados erroneamente, e $+1$ evidencie um agrupamento perfeito [19]. Já o retorno do índice de valor 0 aponta a sobreposição de *clusters*, um resultado indesejado para a análise de dados. Essa avaliação considera o quanto próximo um ponto de um determinado conjunto de dados está de outro ponto situado em seu vizinho.

O *Silhouette Score* é calculado utilizando a distância média intra *cluster* e a distância média entre um *cluster* e o seu vizinho [19]. O cálculo da métrica é dado conforme a equação (4):

$$S = \frac{b - a}{\max(a, b)} \quad (4)$$

Sendo:

- a é a distância média intra-*cluster*;
- b é a distância média do *cluster* mais próximo.

Assim, pode-se dizer que o *Silhouette Score* é uma métrica sobre o nível de coesão de um agrupamento e o de separação entre eles, sendo de grande importância para grandes conjuntos de dados os quais a visualização dos *clusters* é inviável [20].

c.3. Índice de Calinski-Harabasz (CH)

A métrica Calinski-Harabasz ou também nomeada de Critério de Razão de Variância, é frequentemente empregada na avaliação de técnicas de agrupamento [21].

Para se calcular o índice de Calinski-Harabasz deve-se realizar os seguintes passos [22]:

- *Overall within-cluster variance* (SS_w)

Realizar o cálculo da *overall within-cluster variance* (SS_w), no português “variação geral no *cluster*”, que consiste na soma dos quadrados da distância de cada ponto em relação ao baricentro de seu respectivo *cluster*, por meio da equação (5):

$$SS_w = \sum_{i=1}^k \sum_{x \in C_i} \|x - m_i\|^2 \quad (5)$$

Sendo:

- C_i é o *cluster* do i -ésimo *cluster*;
- X é um ponto pertencente ao *cluster* C_i ;
- m_i é o baricentro do *cluster* C_i .

- *Overall between-cluster-variance* (SS_b)

Realizar o cálculo da *overall between-cluster variance* (SS_b), no português “variação geral entre *clusters*”, calculada a partir da diferença entre a soma dos quadrados da distância de cada ponto para o baricentro do conjunto de dados e o *overall within-cluster variance* (SS_w), por meio da equação (6):

$$SS_b = (\sum_{i=1}^k \sum_{x \in C_i} \|x - C\|^2) - SS_w \quad (6)$$

Sendo:

- C_i é o i -ésimo *cluster*;
- X é um ponto pertencente ao *cluster* C_i ;
- C é o baricentro do conjunto de dados.

E por fim, utiliza-se os valores encontrados anteriormente de SS_w e SS_b para calcular o índice de Calinski-Harabasz, como pode ser visto na equação (7):

$$CH = \frac{SS_b}{SS_w} \times \frac{N - K}{K - 1} \quad (7)$$

Sendo:

- CH é o Índice de Calinski-Harabasz;
- N é a quantidade de pontos;
- K é a quantidade de *clusters*.

Caso a variação geral entre *clusters* seja maior que variação geral dentro de cada um deles, o índice será elevado, indicando resultado satisfatório na tarefa de *clusterização*. Pois quanto maior o índice, mais densos e separados estão os agrupamentos dos dados [22].

O uso do Calinski-Harabasz permite identificar a coesão dos conjuntos formados sem requerer alto nível de processamento, pois o seu tempo de execução é linear em relação ao número de pontos de dados, ou seja, possui uma complexidade $O(N)$. Contudo, a ferramenta apresenta um bom desempenho frente a outras métricas de validação de agrupamento [23].

III. REVISÃO DA BIBLIOGRAFIA

O objetivo desta revisão bibliográfica é avaliar e comparar o desempenho de diferentes métodos de remoção de *outliers* e agrupamento de dados, principalmente para o *software Eye Tracking*.

Para realizar a busca foram utilizadas as seguintes palavras-chave: *Eye Tracking*, IQR, ECOD, LOF e *K-means*. Ao invés de empregar uma estratégia de pesquisa que combinasse as palavras-chave simultaneamente, optou-se por explorar cada termo isoladamente. Desse modo, foram selecionados seis artigos referentes aos temas abordados nesta seção.

A. A practical guide on conducting Eye Tracking studies in software engineering (2020)

Sharafi et al. [24] apresentam um estudo abrangente sobre a utilização de rastreamento ocular principalmente em engenharia de *software*. O objetivo principal é fornecer orientações práticas para pesquisadores interessados em projetar, executar e relatar estudos de rastreamento ocular nessa área. A metodologia proposta abrange desde a configuração e calibração dos equipamentos de rastreamento ocular até a análise e interpretação dos

dados coletados. Um destaque importante é dado à calibração, sendo um processo crucial para garantir a precisão e confiabilidade dos dados de rastreamento ocular. Os resultados obtidos nesse estudo incluem exemplos de estudos anteriores que utilizaram rastreadores oculares em engenharia de software, bem como uma lista de métricas, visualizações e análises estatísticas comumente utilizadas para analisar e relatar os dados de rastreamento ocular. Fornece uma base sólida de como utilizar o rastreamento ocular, destacando a importância da calibração adequada e fornecendo orientações práticas para o planejamento e execução.

B. Evaluation of appearance-based Eye Tracking calibration data selection (2020)

Li, Zhan e Yang [25] oferecem uma análise aprofundada da avaliação de dados de calibração para o rastreamento ocular. O objetivo do estudo é analisar o impacto da seleção de dados e da distribuição de alvos de calibração na precisão do *software* para cada indivíduo. A metodologia proposta no estudo envolve o treinamento de uma rede neural convolucional (*CNN*) e o uso de regressão via vetores de suporte (*SVR*) para a calibração. Os resultados destacam que o aumento no número de alvos de calibração resulta em uma redução no erro de estimativa do olhar. No entanto, a forma da distribuição dos alvos de calibração também desempenha um papel crucial, com a distribuição em forma de retângulo apresentando um desempenho superior em termos de precisão. O artigo ressalta a importância de uma seleção adequada dos dados de calibração e sugere que a distribuição dos alvos de calibração deve ser cuidadosamente considerada ao escolher um número limitado de dados para a calibração. Além disso, o estudo discute o uso de capturas sob condições de iluminação semelhantes.

C. How to Find Outliers — 4 Ways with Examples and Explanation (2023)

Bhandari [26] discute quatro métodos para identificar *outliers* em um conjunto de dados: o método de classificação, o método de visualização de dados, os testes estatísticos (z scores) e o método do intervalo interquartil (IQR). O objetivo do artigo é ajudar os leitores a identificar e lidar com *outliers* em seus conjuntos de dados. O artigo também discute a calibração do *software* de Eye Tracking e como os *outliers* podem afetar a precisão dos resultados. O artigo menciona que os *outliers* podem ser agrupados em *clusters*, correspondendo aos períodos em que o sujeito não estava olhando para o alvo de calibração. O artigo também menciona que a calibração do *Eye Tracking* pode ser difícil com sujeitos que não cooperam, como primatas e bebês. O artigo conclui que é importante identificar cuidadosamente os *outliers* em um conjunto de dados e lidar com eles de maneira adequada para obter resultados precisos.

D. ECOD: Unsupervised Outlier Detection Using Empirical Cumulative Distribution Functions (2022)

Li et al. [10] apresenta o ECOD como alternativa às limitações dos métodos existentes, como alto custo computacional, ajuste de hiperparâmetros complexo e limitada interpretabilidade. A metodologia proposta pelo ECOD consiste em estimar a distribuição subjacente dos dados de entrada de forma não

paramétrica, calcular as probabilidades de cauda por dimensão para cada ponto de dados e, em seguida, computar um *score* de *outlier* agregando as probabilidades de cauda estimadas. Os resultados mostram que o ECOD supera 11 métodos de referência em termos de precisão, eficiência e escalabilidade em 30 conjuntos de dados de referência. Além disso, o artigo destaca que o ECOD é fácil de interpretar, fornecendo informações sobre como cada dimensão contribui para o *score* de *outlier*. O *software* ECOD foi calibrado por meio de extensos experimentos em 30 conjuntos de dados de referência, sendo disponibilizado como uma implementação em *Python* de fácil uso e escalabilidade.

E. Model-Based Outlier Detection System with Statistical Preprocessing (2016)

Singh e Leavline [27] propõem um sistema de detecção de *outliers* baseado em modelos com pré-processamento estatístico. O objetivo é detectar partes errôneas ou objetos anormais em populações definidas. A metodologia proposta emprega o uso do Intervalo Interquartil (IQR) para pré-processar os dados de treinamento, junto com a aplicação do algoritmo de *clustering K-means* para construir o modelo de detecção de *outliers*. O desempenho do sistema é avaliado por meio de métricas, como o erro quadrático médio e o tempo necessário para construir o modelo. O algoritmo IQR foi aplicado para identificar e remover os *outliers* dos conjuntos de dados, enquanto o algoritmo *K-means* foi empregado para a construção do modelo de detecção de *outliers*. Os resultados destacam que o sistema proposto reduz consideravelmente o erro quadrático médio e o tempo necessário para construir o modelo em comparação com a detecção de *outliers* sem o pré-processamento estatístico.

F. A Review of Local Outlier Factor Algorithms for Outlier Detection in Big Data Streams (2020)

Alghushairy et al. [11] fazem uma revisão bibliográfica que analisa a literatura existente sobre algoritmos de detecção de *outliers* locais em ambientes de fluxo de dados, com foco especial no algoritmo LOF. Os resultados destacam a eficácia e precisão desse *software* na detecção de *outliers*, ressaltando a importância da calibração para garantir sua efetividade. Além disso, destaca-se a importância da detecção de *clusters* e como esse aspecto pode contribuir significativamente para identificar *outliers*. O artigo aborda também a calibração de um *software* usando o algoritmo LOF, enfatizando a necessidade de selecionar criteriosamente os parâmetros para assegurar a eficácia do algoritmo. Métodos de calibração do LOF, como a validação cruzada e a otimização de parâmetros são discutidos e o artigo destaca a importância de considerar o contexto específico de cada aplicação ao escolher os parâmetros para esse *software*. Os trabalhos revisados nesta seção apresentaram diversas abordagens, modelos e técnicas que podem ser usadas para a melhoria da calibração do *Software Eye Tracking*. Dessa forma, as informações extraídas dos artigos serão utilizadas na seção de “experimentos”, uma vez que o intuito deste trabalho é avaliar as melhores técnicas de calibração e remoção de *outliers*.

IV. PROPOSTA

Neste trabalho são abordadas diferentes técnicas para análise de calibração de *software* de rastreamento ocular, tendo como objetivo otimizar a precisão dos resultados obtidos com o *software Eye Tracking*. O fluxo de funcionamento do trabalho proposto está descrito na forma de um fluxograma (Figura1).

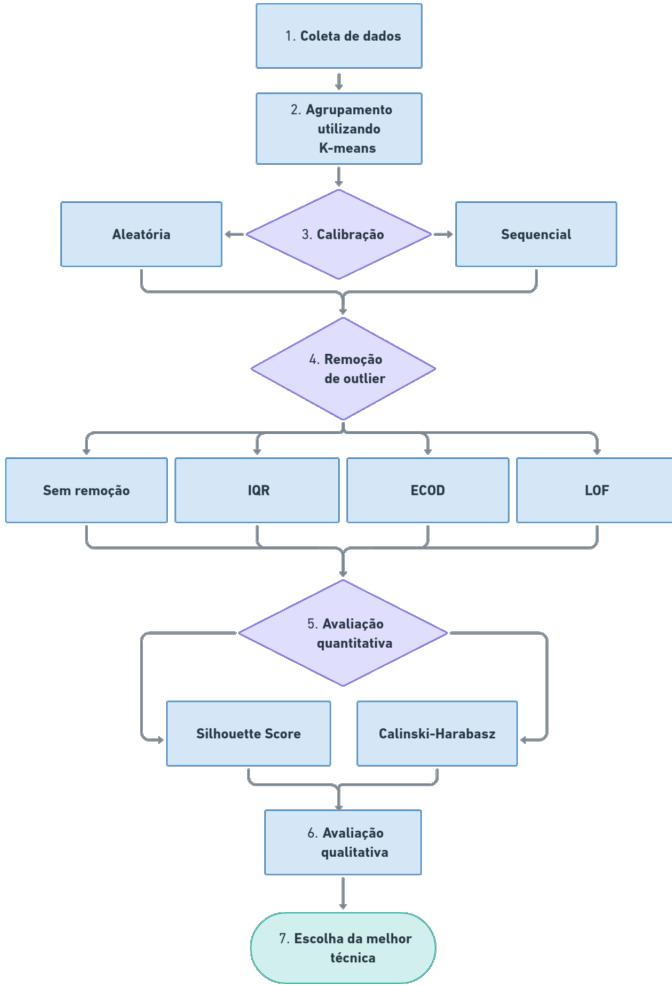


Fig. 1. Fluxograma que descreve o funcionamento do trabalho.

Inicialmente são realizadas as coletas dos dados provenientes do rastreamento ocular de indivíduos voluntários para a pesquisa, desse modo os voluntários realizam a calibração do *software* das seguintes formas:

- Calibração Sequencial: na calibração sequencial, os pontos de calibração aparecem em sequência na tela do computador, de forma que o primeiro ponto seja plotado próximo à coordenada (0, 0) da tela, o ponto seguinte é plotado em sua sequência no sentido da esquerda para a direita e dessa forma o último ponto de calibração será plotado próximo ao canto inferior direito, a coordenada pode variar conforme a resolução do computador utilizado no processo. Desta forma é possível que o voluntário preveja a localização do ponto seguinte a ser mostrado na tela;
- Calibração Aleatória: dessemelhante ao método anterior, a plotagem dos pontos de calibração ocorre de forma aleatória ao decorrer do processo, não seguindo o padrão de sequência. Nesse método o voluntário não sabe qual

será a localização do próximo ponto a ser apresentado na tela.

Após a calibração, é realizado o agrupamento utilizando o algoritmo *K-means* para ser possível aplicar as técnicas de remoção de *outliers*. O estudo prevê a aplicação de três diferentes métodos para remoção de *outliers* nos pontos captados na fase de calibração, já destacadas na seção de “Revisão da Teoria”, sendo elas:

- Não remoção de *outliers*: essa abordagem se refere a não remoção dos valores discrepantes em relação ao restante do conjunto de dados, a fim de comparação com a utilização das demais técnicas que visam a remoção dos valores atípicos;
- IQR (Intervalo Interquartil): a técnica proposta diz respeito a utilização de análise estatística para remover possíveis valores considerados atípicos nos conjuntos de dados;
- ECOD (*Empirical-Cumulative-Distribution-Based Outlier Detection*): corresponde a uma técnica baseada no cálculo da distribuição empírica cumulativa dos dados que visa identificar e remover pontos que se dispersam significativamente do restante do conjunto;
- LOF (*Local Outlier Factor*): o fator de *outlier* local de uma amostra é calculado como a média das razões da densidade local em que aquele ponto está inserido e das densidades locais dos pontos ao redor. Um valor de LOF consideravelmente maior do que 1, indica que aquela amostra é um valor atípico.

Para a validação dos métodos utilizados, faz-se necessário a utilização de técnicas quantitativas e qualitativas de avaliação. Desse modo, foram selecionados os seguintes algoritmos para a validação quantitativa das técnicas descritas anteriormente:

- *Silhouette Score*: é empregado a métrica de avaliação de qualidade de agrupamento, em que é avaliada a distância entre os *cluster* e a proximidade dos pontos dentro desses agrupamentos realizados pelo *K-means*;
- *Calinski-Harabasz*: possui o mesmo objetivo do algoritmo citado acima. Visa avaliar quantitativamente a coerência entre os *clusters* formados com os dados obtidos na calibração por meio da dispersão média entre os *clusters* e a dispersão média dos pontos presentes nos *clusters*.

Para complementar a validação dos algoritmos empregados no estudo, é aplicado o método de avaliação qualitativa. Desse modo são coletados votos dos voluntários para os métodos que julgarem mais eficientes e que considerem com o melhor resultado, considerando usabilidade e precisão do rastreamento ocular visualizado no gráfico de calor plotado ao final do teste.

V. EXPERIMENTOS

Nesta seção, é descrita detalhadamente a metodologia aplicada na realização dos experimentos e são apresentados e discutidos os resultados por meio das métricas quantitativas e qualitativas descritas na proposta.

A. Metodologia

A metodologia adotada nesse experimento visa explorar as funcionalidades das técnicas aplicadas para a calibração do soft-

ware Eye Tracking. Os testes foram realizados com sete participantes que efetuaram a calibração oito vezes referente a todas as combinações possíveis entre os métodos de remoção de *outlier* (IQR, ECOD, LOF) e as formas de calibração (sequencial ou aleatória) e assistiram a um vídeo exemplo, permitindo que o sistema registrasse e analisasse os movimentos oculares. Essa abordagem promete não apenas avaliações quantitativas acerca da remoção de *outliers*, mas também uma compreensão qualitativa da qualidade do resultado da detecção.

a.1. Aspectos do Software

O software utilizado no estudo foi desenvolvido anteriormente pela equipe utilizando a linguagem *Python* e possui como principais funcionalidades: captura de dados, calibração, escalonamento e exibição dos dados. A exibição é apresentada em forma de gráficos de calor (*heatmap*), como pode ser visualizado na (Figura 2), de modo que as áreas de menor interação apresentam uma coloração mais fria e as áreas com maior visitação do olhar são representadas por cores quentes.

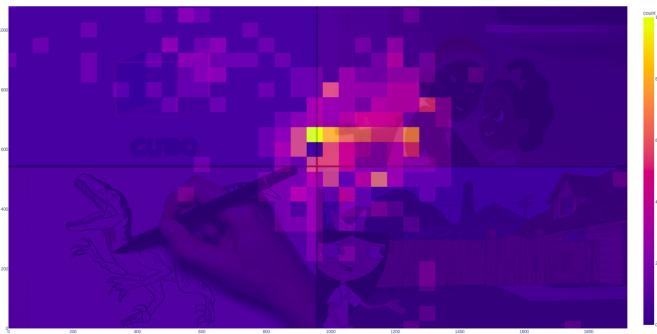


Fig. 2. Exemplo de um gráfico de calor exibido ao final da captura.

Para a realização do teste foi utilizado um *notebook* com resolução de tela de 1920×1080 . Na calibração, foram utilizadas 4 colunas por 3 linhas, com um total de 12 pontos, se considerar que a razão de aspecto da tela é de 16 : 9 teríamos um total de 144 pontos de calibração, o que seria inviável considerando o tempo exigido para o processo. Para um resultado mais detalhado do gráfico de calor, foram definidos os parâmetros *nbinsX* com o valor de 64 e *nbinsY* com o valor 32, que dizem respeito ao *grid* do *heatmap*.

A duração total da calibração é de um minuto e trinta e seis segundos, visto que cada ponto é exibido na tela por um período de oito segundos. Já a taxa de amostragem realizada pelo algoritmo é de 0.01 segundos, ou seja, a cada 10 milissegundos uma coordenada é captada pela *webcam* utilizando a técnica de oculografia por vídeo (VOG). Naturalmente, esta taxa de captura é teórica, pois tempo de processamento realizado para localização da pupila também deve ser considerado.

Em todos os testes, utilizou-se o método de *K-means* para efetuar o agrupamento de dados.

a.2. Condições Ambientais

Primeiramente, foi considerado a iluminação do ambiente em que foram realizados os testes, visto que esse parâmetro é essencial para a melhor captura de dados e precisão do algoritmo. A iluminação utilizada foi luz artificial branca e os participantes foram instruídos a se sentarem em um local estratégico de modo

que não houvesse sombra em seus olhos. Todos os participantes se sentaram no mesmo local, garantindo que a luminosidade não variasse entre um teste e outro.

Concomitantemente, a ergonomia é um aspecto fundamental dessa avaliação, visando não apenas a precisão dos resultados, mas também o conforto dos participantes. O computador utilizado nos testes foi disposto a uma altura de 16 centímetros acima da mesa (Figura 3) e os participantes foram instruídos a manterem a cabeça estática, movimentando somente os olhos durante todo o experimento.



Fig. 3. Exemplo de posicionamento durante a realização do teste.

Os participantes foram posicionados centralizados em relação à câmera, de maneira que a mesma ficasse levemente abaixada do nariz (Figura 4).



Fig. 4. Exemplo de posicionamento durante a realização do teste.

a.3. Etapas realizadas

Além de todas essas condições favoráveis, deve-se atentar ao processo de realização dos testes e, desse modo, as etapas a seguir foram realizadas:

- 1. Instrução:** em um primeiro momento, os participantes foram instruídos sobre o funcionamento do experimento a ser realizado. Logo em seguida, o indivíduo foi centralizado à frente da *webcam* para a captação dos movimentos oculares. Na etapa de calibração, o integrante olhou diretamente para os pontos dispostos na tela. Na etapa de teste, o vídeo apresentado foi assistido;

2. **Calibração:** o indivíduo manteve seu olhar fixo nos pontos correspondentes de calibração. Esses pontos podem ser sequenciais ou aleatórios, estando dispostos em uma tela preta que permitirá a total atenção nos pontos brancos, como na (Figura 5);

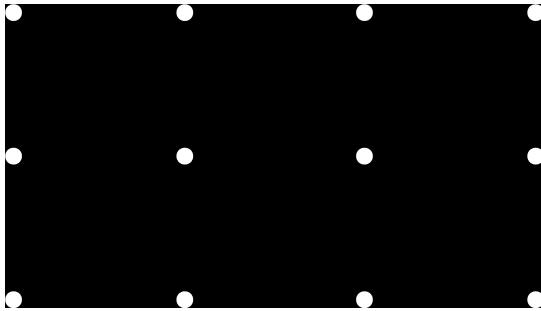


Fig. 5. Posicionamento dos pontos durante a calibração 4x3.

3. **Teste:** na etapa do teste, um vídeo, dividido em quatro quadrantes na tela com cada um contendo um vídeo diferente, foi dispõsto aos participantes (Figura 6). Isso permite que o indivíduo selecione o seu interesse desejado e, assim, avaliar, por meio do *heatmap*, se sua interação com o *software* está precisa;



Fig. 6. Vídeo exibido durante o experimento.

4. **Avaliação qualitativa:** na avaliação qualitativa, o indivíduo visualizou o vídeo para todos os oito testes, sendo questionado a respeito de qual o melhor resultado de detecção, baseado no *heatmap* gerado e nas áreas em que ele fixou seu olhar;
 5. **Avaliação quantitativa:** na avaliação quantitativa, onde as métricas de avaliação *Silhouette Score* e *Calinski-Harabasz* foram utilizadas, os índices retornados foram salvos para posteriormente serem analisados.

B. Resultados e Discussão

Após a realização dos testes, foram armazenados os valores dos índices de *Silhouette Score* e *Calinski-Harabasz*, assim como as imagens geradas durante cada teste realizado por cada participante.

Dentre os dados armazenados, têm-se os gráficos de dispersão gerados após a calibração, sendo um para amostras sem a remoção de *outliers* (Figura 7) e um com a remoção de *outliers* (Figura 8) referente ao método utilizado no teste em questão, permitindo uma análise visual da qualidade da *clusterização*.

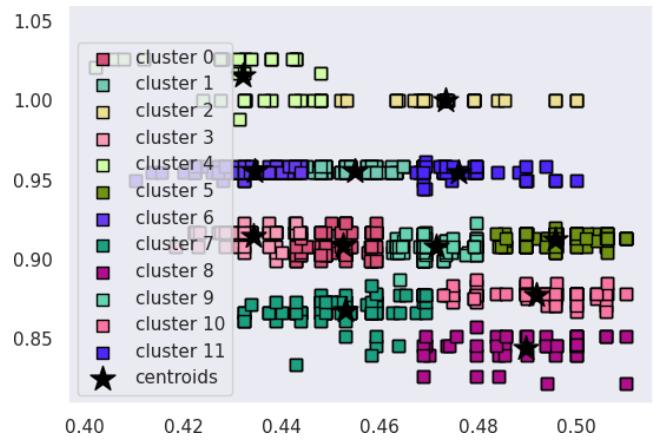


Fig. 7. Exemplo de gráfico de dispersão antes da remoção dos *outliers*.

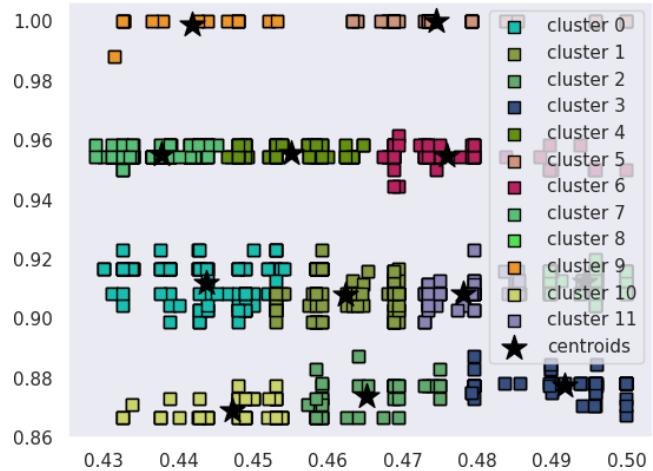


Fig. 8. Exemplo de gráfico de dispersão após a remoção dos *outliers* utilizando calibração sequencial e o método ECOD.

Além disso, durante a captura dos dados, foi questionado a cada participante para qual quadrante ele estava direcionando o seu olhar, e o *heatmap* resultante da captura foi armazenado (Figura 9), permitindo que no final do teste fosse realizada a comparação precisa entre a região observada e o gráfico de calor gerado. Diante disso, foi possível efetuar a avaliação qualitativa do *software* após a realização de todos os testes pelo participante.

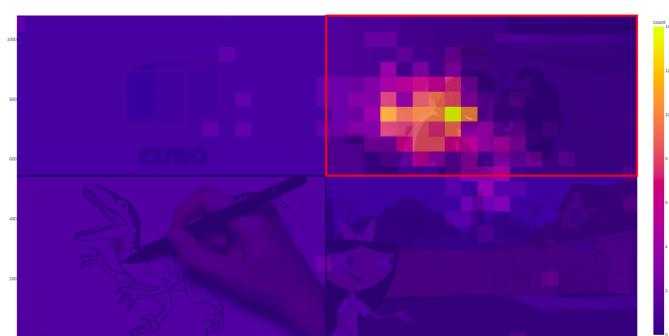


Fig. 9. Exemplo de *heatmap* com quadrante de interesse em destaque.

Os índices de *Calinski-Harabasz* e *Silhouette Score* foram salvos em arquivos de texto para serem utilizados como métricas de avaliação quantitativa.

A partir dos dados coletados foram realizados cálculos de média e desvio-padrão. O aumento na média de ambos os índices indica uma qualidade superior no agrupamento, assim como a redução no desvio-padrão para ambos os índices sugere um resultado mais consistente. Também foram registrados os votos referentes à avaliação qualitativa, resultando na tabela I.

TABELA I
RESULTADOS OBTIDOS NO EXPERIMENTO

K	O	CH_M	CH_{SD}	SS_M	SS_{SD}	V
S	-	3955,52	2608,97	0,49	0,03	1
S	IQR	3083,18	1170,07	0,47	0,05	1
S	ECOD	5466,12	3715,01	0,52	0,07	0
S	LOF	4797,10	2330,52	0,56	0,09	0
A	-	6024,97	2988,68	0,50	0,07	1
A	IQR	7047,92	3401,18	0,49	0,04	2
A	ECOD	7460,87	3786,84	0,54	0,06	1
A	LOF	7899,10	7899,12	0,50	0,10	1

Sendo:

- K : tipo de calibração: sequencial (S) ou aleatório (A);
- O : remoção de *outlier* (nenhum, IQR, ECOD ou LOF);
- CH_M : média do índice Calinski-Harabasz;
- CH_{SD} : desvio-padrão do índice Calinski-Harabasz;
- SS_M : média do *Silhouette Score*;
- SS_{SD} : desvio-padrão do *Silhouette Score*;
- V : quantidade de votos.

Para fins de comparação entre as duas diferentes métricas de avaliação quantitativas, foi realizado a normalização das médias e desvios-padrões de Calinski-Harabasz e *Silhouette Score*. Ao normalizar os dados, pode-se perceber que todos foram ajustados para uma faixa de valores entre 0 e 1. Para o cálculo de normalização da média foi utilizada a equação 8:

$$M' = \frac{M}{\max(\vec{M})} \quad (8)$$

Sendo:

- M' é a média depois da normalização;
- M é a média antes da normalização;
- \vec{M} é o conjunto de médias;
- $\max(\vec{M})$ é o maior valor de média do conjunto.

A normalização do desvio-padrão foi feita conforme a equação (9):

$$SD' = \frac{\min(\vec{SD})}{SD} \quad (9)$$

Sendo:

- SD' é o desvio-padrão depois da normalização;
- SD é o desvio-padrão antes da normalização;
- \vec{SD} é o conjunto de desvios-padrões;
- $\min(\vec{SD})$ é o menor valor de desvio-padrão do conjunto.

Os valores normalizados podem ser visualizados pela tabela II. Observa-se que o método LOF combinado com a calibração aleatória possui a maior média normalizada para o

índice Calinski-Harabasz, atingindo o valor de 1, já o menor valor de desvio-padrão do índice diz respeito ao método IQR juntamente com a calibração sequencial também normalizado para 1.

Referindo-se ao método *Silhouette Score*, percebe-se que o maior valor de média também diz respeito ao método LOF, porém quando combinado com a calibração sequencial, já o menor desvio-padrão apresentado é evidenciado na captura em que nenhum método de remoção de *outlier* foi empregado.

TABELA II
RESULTADOS OBTIDOS NO EXPERIMENTO COM VALORES NORMALIZADOS

K	O	CH'_M	CH'_{SD}	SS'_M	SS'_{SD}	V
S	-	0,501	0,448	0,875	1,000	1
S	IQR	0,390	1,000	0,839	0,600	1
S	ECOD	0,692	0,315	0,929	0,429	0
S	LOF	0,607	0,502	1,000	0,333	0
A	-	0,763	0,392	0,893	0,429	1
A	IQR	0,892	0,344	0,875	0,750	2
A	ECOD	0,945	0,309	0,964	0,500	1
A	LOF	1,000	0,148	0,893	0,300	1

Sendo:

- K : tipo de calibração: sequencial (S) ou aleatório (A);
- O : remoção de *outlier* (nenhum, IQR, ECOD ou LOF);
- CH'_M : média normalizada do índice Calinski-Harabasz;
- CH'_{SD} : desvio-padrão normalizado do índice Calinski-Harabasz;
- SS'_M : média normalizada do *Silhouette Score*;
- SS'_{SD} : desvio-padrão normalizado do *Silhouette Score*;
- V : quantidade de votos.

Por fim, efetuou-se a soma das médias normalizadas com os desvios-padrões também normalizados para cada métrica de avaliação. Posteriormente foram somados os resultados dos valores resultantes de Calinski-Harabasz com os valores resultantes de *Silhouette Score*. De modo que, ao final, tem-se uma coluna Q na tabela III como *score* consolidado para cada combinação entre método de calibração (sequencial ou aleatória) e método de remoção de *outlier* (sem remoção, IQR, ECOD e LOF) baseados na avaliação qualitativa realizada pelos algoritmos Calinski-Harabasz e *Silhouette Score*.

TABELA III
RESULTADOS OBTIDOS DA SOMA DOS VALORES CONSOLIDADOS

K	O	CH'_{M+SD}	SS'_{M+SD}	Q	V
S	-	0,949	1,875	2,824	1
S	IQR	1,390	1,439	2,830	1
S	ECOD	1,007	1,357	2,364	0
S	LOF	1,109	1,333	2,443	0
A	-	1,154	1,321	2,476	1
A	IQR	1,236	1,625	2,861	2
A	ECOD	1,254	1,464	2,718	1
A	LOF	1,148	1,193	2,341	1

Sendo:

- K : tipo de calibração: sequencial (S) ou aleatório (A);
- O : remoção de *outlier* (nenhum, IQR, ECOD ou LOF);
- CH'_{M+SD} : soma das média e desvio-padrão normalizados do índice Calinski-Harabasz;
- SS'_{M+SD} : soma das média e desvio-padrão normalizados do *Silhouette Score*;
- Q : *score* consolidado;
- V : quantidade de votos.

Deve-se salientar que para dois dos sete participantes os resultados não foram satisfatórios e, embora as condições de posicionamento e luminosidade durante os testes tenham sido as mesmas para todos os participantes, os resultados apresentados para os dois testes mencionados foram imprecisos. Ambos participantes cujos testes não apresentaram resultados fidedignos alegaram certa dificuldade em se concentrarem durante a calibração, mencionando que em alguns momentos desviavam os olhos dos pontos accidentalmente.

Observa-se na tabela III que os métodos que obtiveram maior valor final foram respectivamente: IQR + Calibração aleatória, IQR + Calibração sequencial e Sem remoção de *outlier* + Calibração sequencial. Nota-se que essas combinações apresentaram valores relativamente altos para média e baixos desvios-padrões, apontando uma maior consistência no agrupamento de dados e maior remoção de *outliers*.

Vale ressaltar que entre os métodos abordados no estudo, o IQR é o de mais fácil entendimento e implementação, visto que o método se baseia em um cálculo simples estatístico de quartis.

VI. CONCLUSÃO

O trabalho em questão destacou a importância e os desafios enfrentados para a calibração de um *software Eye Tracking*, um ponto crucial para o sucesso da captura dos dados e precisão dos resultados.

Além disso, a solução proposta para o rastreamento ocular apresentada no estudo possui baixo custo por não demandar *hardware* específico para a captação dos movimentos oculares, diferente dos métodos de bobina de busca escleral, oculografia por infravermelho e eletrooculografia. Sendo o método menos invasivo e desconfortável dentre os quatro mencionados.

Para melhorar a calibração do *software* de rastreamento ocular citado, foram escolhidos três algoritmos para realizar a remoção de *outliers* dos dados captados durante a calibração, sendo eles: IQR, ECOD e LOF. Antes do processo de remoção de *outliers*, foi realizado o agrupamento dos dados por meio de um algoritmo de *clusterização*, *K-means*.

Para avaliar o desempenho dos métodos, foi proposto duas maneiras de avaliação: uma qualitativa, que contou com a opinião dos participantes sobre qual o melhor gráfico de calor apresentado, e outra quantitativa, realizada pelas métricas de avaliação Callinski-Harabasz e *Silhouette Score*.

Durante a realização dos experimentos foram identificados diversos parâmetros ambientais e ergonômicos que influenciam significativamente na captura dos dados, como a iluminação, altura dos olhos em relação à câmera, centralização em relação

ao computador, utilização de óculos e a necessidade de manter a cabeça estática durante todo o processo. Esses detalhes notados confirmam a dificuldade de utilização do modelo de rastreamento ocular por oculografia por vídeo (VOG).

Após a realização de oito testes com cada um dos sete participantes, foi possível analisar quais métodos tiveram melhores resultados. Na análise qualitativa, o método que obteve maior sucesso na remoção de *outliers*, com $V = 2$ votos, foi a combinação da calibração aleatória com o método de remoção de *outlier* IQR.

De mesmo modo, a combinação da calibração aleatória com o método IQR também obteve maior pontuação na avaliação quantitativa realizada pelas métricas Calinski-Harabasz e *Silhouette Score*, com um *score* consolidado $Q = 2,861$.

Podemos concluir que o modelo de calibração aleatória combinada com o método IQR de remoção de *outlier* apresenta um resultado satisfatório na realização de remoção de valores atípicos identificados na captura de coordenadas durante o processo de calibração, contribuindo com um resultado mais preciso do rastreamento ocular.

REFERÊNCIAS

- [1] Samuel Correia, Fernando Augusto Cunha, Erick Franco, Leonardo José Silva e José Alberto Silva. “Tecnologia Eye Tracking: Aplicações e Implicações para a Indústria 4.0”. Em: *Anais do Encontro Nacional de Engenharia de Produção – Enegep* (2017), pp. 2–5.
- [2] Andrew Duchowski. *Eye Tracking Methodology: Theory and Practice*. Springer, Cham, 2007.
- [3] Ana Barreto. “Eye tracking como método de investigação aplicado às ciências da comunicação”. Em: *Revista Comunicando* 1 (2012), pp. 168–186.
- [4] Isayas Berhe Adhanom, Paul MacNeilage e Eelk Folmer. “Eye Tracking in Virtual Reality: a Broad Review of Applications and Challenges”. Em: *Virtual Reality* 27 (2023), pp. 1481–1505.
- [5] Niilo V. Valtakari, Ignace T. C. Hooge, Charlotte Viktorsson, Pär Nyström, Terje Falck-Ytter e Roy S. Hessels. “Eye tracking in human interaction: Possibilities and limitations”. Em: *Behavior Research Methods* 53 (2021), pp. 1592–1608.
- [6] Benjamin T. Carter e Steven G. Luke. “Best practices in eye tracking research”. Em: *International Journal of Psychophysiology* 155 (2020), pp. 49–62. ISSN: 0167-8760.
- [7] Ahmad F Klaib, Nawaf O Alsrehin, Melhem Wasen Y, Haneen O Bashtawi e Aws A Magableh. “Eye tracking algorithms, techniques, tools, and applications with an emphasis on machine learning and Internet of Things technologies”. Em: *Expert Systems with Applications* 166 (2021), p. 114037. ISSN: 0957-4174.
- [8] Hoppen, Joni and Prates, Wlademir. *SpamAssassin Public Mail Corpus*. 2017. URL: <https://www.aquare.la/o-que-sao-outliers-e-como-trata-los-em-uma-analise-de-dados/>.

- [9] Ekta Maini. *Interquartile Range to Detect Outliers in Data*. 2023. URL: <https://www.geeksforgeeks.org/interquartile-range-to-detect-outliers-in-data/>.
- [10] Zheng Li, Yue Zhao, Xiyang Hu, Nicola Botta, Cezar Ionescu e George H. Chen. “ECOD: Unsupervised Outlier Detection Using Empirical Cumulative Distribution Functions”. Em: *CoRR* abs/2201.00382 (2022).
- [11] Omar Alghushairy, Raed Alsini, Terence Soule e Xiaogang Ma. “A Review of Local Outlier Factor Algorithms for Outlier Detection in Big Data Streams”. Em: *Big Data and Cognitive Computing* 5.1 (2021). ISSN: 2504-2289.
- [12] Erich Schubert, Arthur Zimek e Hans-Peter Kriegel. “Local outlier detection reconsidered: a generalized view on locality with applications to spatial, video, and network outlier detection”. Em: 28 (2014), pp. 190–237.
- [13] Marcelo K Matte e Maria do Carmo Nicoletti. “Revisão de Estratégias para a Aceleração do Algoritmo k-Means”. Em: *Expert Systems with Applications* 166 (2019), pp. 1–6. ISSN: 2447-4703.
- [14] Renato Cruz. *As lições dos Laboratórios Bell*. 2012. URL: <https://www.estadao.com.br/link/renato-cruz/as-licoes-dos-laboratorios-bell/>.
- [15] Cloud Software Group. *O que é aprendizagem não supervisionada?* 2023. URL: <https://www.tibco.com/pt-br/reference-center/what-is-unsupervised-learning>.
- [16] Tussevana Miguel. *K-means Clustering (agrupamento k-means)*. 2023. URL: <https://aprenderdatascience.com/k-means-clustering-agrupamento-k-means/>.
- [17] Bruno Anastaciol. *K-means: o que é, como funciona, aplicações e exemplo em Python*. 2020. URL: <https://medium.com/programadores-ajudando-programadores/k-means-o-que-%C3%A9-como-funciona-aplica%C3%A7%C3%A3o-B5es-e-exemplo-em-python-6021df6e2572>.
- [18] Samina. *What is Silhouette Score?* 2023. URL: <https://www.educative.io/answers/what-is-silhouette-score>.
- [19] F. Pedregosa, G. Varoquaux, A. Gramfort e et al. “Scikit-learn: Machine Learning in Python”. Em: *Journal of Machine Learning Research* 12 (2011), pp. 2825–2830.
- [20] Shubham Koli. “How to evaluate the performance of clustering algorithms using Silhouette Coefficient”. Em: *Medium* (2023). URL: <https://medium.com/@MrBam44/how-to-evaluate-the-performance-of-clustering-algorithms-3ba29cad8c03>.
- [21] Fatih Emre Ozturk. “Unsupervised learning in R: Determination of cluster number”. Em: *Medium* (2023). URL: <https://medium.com/@ozturkfemre/unsupervised-learning-determination-of-cluster-number-be8842cdb11>.
- [22] Gilney Junior. “Qualidade de Agrupamentos (Ciência de Dados) - Gilney Junior - Medium”. Em: *Medium* (2021). URL: <https://medium.com/@gilneyjnr/qualidade-de-agrupamentos-ci%C3%A3o-Ancia-de-dados-4b1176bef5e5>.
- [23] Suzane Pereira Lima e M. D. Soler Cruz. “A genetic algorithm using Calinski-Harabasz index for automatic clustering problem”. Em: *Revista Brasileira De Computação Aplicada* 12 (2020), pp. 97–106.
- [24] Zohreh Sharafi, Bonita Sharif, Yann-Gaël Guéhéneuc, Andrew Begel, Roman Bednarik e Martha Crosby. “A practical guide on conducting eye tracking studies in software engineering”. Em: *Empirical Software Engineering* 25 (2020), pp. 3128–3174.
- [25] Yuqing Li, Yinwei Zhan e Zhuo Yang. “Evaluation of appearance-based eye tracking calibration data selection”. Em: *IEEE International Conference on Artificial Intelligence and Computer Applications (ICAICA)* (2020), pp. 222–224.
- [26] Pritha Bhandari. “How to Find Outliers — 4 Ways with Examples and Explanation”. Em: *Scribbr* (2023). URL: <https://www.scribbr.com/statistics/outliers/>.
- [27] Danasingh Asir Antony Gnana Singh e E. Jebalamar Leavline. “Model-Based Outlier Detection System with Statistical Preprocessing”. Em: *Journal of Modern Applied Statistical Methods* 15 (2016), pp. 789–801.

AUTORES

Isadora Coelho Faggiani é graduanda em Engenharia Biomédica pelo Instituto Nacional de Telecomunicações (Inatel). Foi monitora de Física I, Física III e Equipamentos Médicos I, e foi bolsista de Iniciação Científica e estagiária no eHealth Innovation Center.



Leonardo Ribeiro Silva é graduando em Engenharia Biomédica pelo Instituto Nacional de Telecomunicações (Inatel). Foi monitor de Transdução de Sinais Biomédicos e Circuitos Elétricos III e bolsista de Iniciação Científica no eHealth Innovation Center de 2021 a 2023. Atualmente é estagiário de Planejamento e Controle de Produção na ProLife Equipamentos Médicos.





eHealth Innovation Center e monitora de Equipamentos Médicos II.

Rita Elizabeth Santos de Almeida é graduanda em Engenharia Biomédica pelo Instituto Nacional de Telecomunicações (Inatel). Técnica em equipamentos médicos pela Escola Técnica em Eletrônica Francisco Moreira da Costa. Foi bolsista Iniciação Científica no eHealth Innovation Center. Atualmente é estagiária no laboratório Center e monitora de Equipamentos Médicos II.



Marcelo Vinícius Cysneiros Aragão é graduado em Engenharia de Computação pelo Instituto Nacional de Telecomunicações (Inatel) em 2014 e mestre em Ciência e Tecnologia da Computação pela Universidade Federal de Itajubá (Unifei) em 2018. Trabalhou de 2011 a 2018 no Inatel Competence Center. É professor de disciplinas de graduação como Inteligência Computacional e Computação Gráfica, coordenador da pós-graduação em Desenvolvimento Móvel e Cloud Computing e doutorando em Engenharia de Telecomunicações no Inatel. Suas áreas de interesse incluem ciência de dados e engenharia de *software*.



Juliano Augusto Nascimento Leite é graduado em Engenharia Elétrica pela Universidade Federal de Itajubá - UNIFEI (2002) e mestre em Engenharia Elétrica pela Universidade Federal de Santa Catarina - UFSC (2006). Atuou no Hospital Tereza Ramos na cidade de Lages como engenheiro clínico. Atuou na UNIPLAC - Universidade do Planalto Catarinense como Pró-Reitor de Pesquisa, Extensão e Pós-Graduação, sendo também coordenador do curso de Engenharia Elétrica e professor dos cursos de Engenharia de Produção e Elétrica. Atuou até 2019 como Field Service Engineer na Philips Health-systems e como professor substituto na UNIFEI. Atualmente é professor auxiliar do quadro de Engenharia Biomédica e coordenador da pós-graduação em Engenharia Clínica e Engenharia Biomédica do Inatel. Também é engenheiro de desenvolvimento na empresa Neurotec.